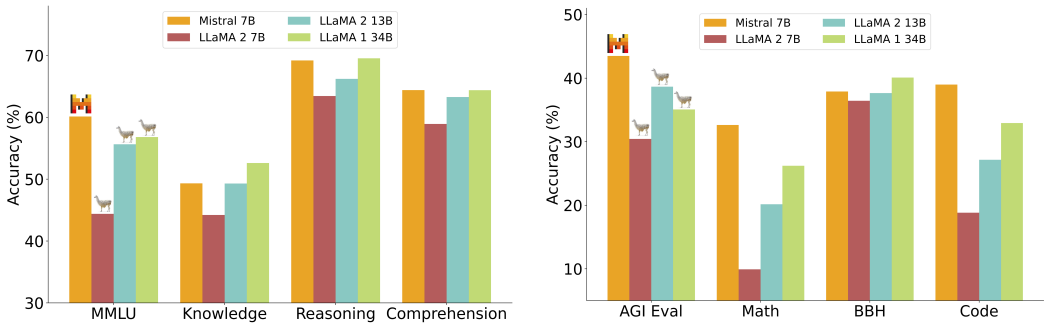


图 4：Mistral 7B 与不同 Llama 模型在广泛基准上的性能。所有模型均通过我们的评估流程在所有度量上重新评估，以确保准确比较。Mistral 7B 在所有基准上显著优于 Llama 2 7B 和 Llama 2 13B。在数学、代码生成和推理基准上，它也大幅超越 Llama 1 34B。

Model	Modality	MMLU	HellaSwag	WinoG	PIQA	Arc-e	Arc-c	NQ	TriviaQA	HumanEval	MBPP	MATH	GSM8K
LLaMA 2 7B	Pretrained	44.4%	77.1%	69.5%	77.9%	68.7%	43.2%	24.7%	63.8%	11.6%	26.1%	3.9%	16.0%
LLaMA 2 13B	Pretrained	55.6%	**80.7%**	72.9%	80.8%	75.2%	48.8%	**29.0%**	**69.6%**	18.9%	35.4%	6.0%	34.3%
Code-Llama 7B	Finetuned	36.9%	62.9%	62.3%	72.8%	59.4%	34.5%	11.0%	34.9%	**31.1%**	**52.5%**	5.2%	20.8%
Mistral 7B	Pretrained	**60.1%**	**81.3%**	**75.3%**	**83.0%**	**80.0%**	**55.5%**	**28.8%**	**69.9%**	**30.5%**	47.5%	**13.1%**	**52.2%**

表 2：Mistral 7B 与 Llama 的比较。Mistral 7B 在所有度量上均优于 Llama 2 13B，并在不牺牲非代码基准性能的情况下接近 Code-Llama 7B 的代码性能。

规模与效率。我们计算了 Llama 2 系列的“等效模型规模”，旨在理解 Mistral 7B 模型在成本-性能谱系中的效率（见图 5）。在推理、理解以及 STEM 推理（特别是 MMLU）评估中，Mistral 7B 的表现与规模超过其三倍的 Llama 2 模型相当。在知识基准上，Mistral 7B 的性能实现了较低的压缩率，为 1.9 倍，这可能是由于其有限的参数数量限制了可存储的知识量。

评估差异。在某些基准上，我们的评估协议与 Llama 2 论文中报告的存在一些差异：1）在 MBPP 上，我们使用人工验证的子集；2）在 TriviaQA 上，我们不提供维基百科上下文。

4 指令微调

为评估 Mistral 7B 的泛化能力，我们在 Hugging Face 仓库公开可用的指令数据集上对其进行了微调。未使用任何专有数据或训练技巧：Mistral 7B – Instruct 模型是一个简单且初步的展示，表明基础模型可以轻松微调以获得良好性能。在表 3 中，我们观察到所得模型 Mistral 7B – Instruct 在 MT-Bench 上表现出优于所有 7B 模型的性能，并与 13B – Chat 模型相当。独立的人工评估在 https://llmboxing.com/leaderboard 上进行。

Model	Chatbot Arena ELO Rating	MT Bench
WizardLM 13B v1.2	1047	7.2
Mistral 7B Instruct	**1031**	**6.84 +/- 0.07**
Llama 2 13B Chat	1012	6.65
Vicuna 13B	1041	6.57
Llama 2 7B Chat	985	6.27
Vicuna 7B	997	6.17
Alpaca 13B	914	4.53

表 3：对话模型比较。Mistral 7B – Instruct 在 MT-Bench 上优于所有 7B 模型，并与 13B – Chat 模型相当。

在此评估中，参与者获得一组问题以及来自两个模型的匿名回答，并被要求选择他们偏好的回答，如图 6 所示。截至 2023 年 10 月 6 日，Mistral 7B 生成的输出被偏好 5020 次，而 Llama 2 13B 为 4143 次。